

République Algérienne Démocratique et Populaire
Ministère de L'Enseignement Supérieur et de la Recherche Scientifique
Université Benyoucef BenKhedda Alger-1



Faculté des Sciences
Département des Mathématiques et Informatiques

Rapport de projet Data Warehouse et OLAP

I. Description du dataset :

Le sujet de ce projet consiste à analyser la gestion des rendez-vous dans un hôpital. Pour étudier comment les patients prennent leurs rendez-vous, quels médecins ils consultent, pour quelles maladies, et comment ils paient leurs consultations. Le but est de mieux comprendre le fonctionnement global du système : le nombre de rendez-vous, les maladies les plus fréquentes, l'activité des médecins, et les paiements réalisés.

Le dataset que j'ai utilisé je l'ai téléchargé de Kaggle, une plateforme qui propose des jeux de données.

J'ai choisi ce dataset parce qu'il contient toutes les informations nécessaires pour créer un modèle décisionnel : les données des rendez-vous (date, statut, motif), les informations des patients et aussi des médecins, les paiements et les modes de prise de rendez-vous.

A	B	C	D	E	F	G	H	I	J	K	L	M
appointment_id	patient_id	doct_id	reason	appointment_date	payment_amount	mode_of_payment	mode_of_appointment	appointment_status	Fname Doc	F Name patient	Gender patient	Genderdoc
5000	1057	1027	Back Pain	27/11/2024	2139	Insurance	Call	Completed	Dr. Najeeb Kamil	M	M	M
5001	1568	1009	Migraine	24/09/2024	1204	Card	In Person	Completed	Dr. Kamran Nimra	F	M	M
5002	449	1024	Diabetes	07/09/2024	2474	Digital Wallet	Call	Completed	Dr. Sheikh Nargis	F	M	M
5003	279	1008	Migraine	30/05/2025	1148	Insurance	Call	Completed	Dr. Hanif Hussain	M	M	M
5004	1089	1001	Hypertension	25/09/2024	2031	Insurance	Online	Cancelled	Dr. Muhamr Samiya	F	M	M
5005	450	1009	Migraine	16/07/2024	2246	Card	Call	Completed	Dr. Sana Maha	F	F	F
5006	540	1027	Headache	31/12/2024	2487	Card	Online	Completed	Dr. Amna Noor	F	F	F
5007	1309	1027	Chest Pain	11/06/2025	867	Card	Online	Scheduled	Dr. Tahir Bushra	F	M	M
5008	734	1027	General Checkup	25/10/2024	1682	Cash	Online	Completed	Dr. Muhamr Sidra	F	M	M
5009	927	1020	Asthma	18/04/2025	2010	Card	Online	Completed	Dr. Sehran Marium	F	M	M
5010	228	1027	General Checkup	27/02/2025	2412	Cash	Online	Cancelled	Dr. Hafsa Sana	F	F	F
5011	464	1027	Fever	28/12/2024	1110	Insurance	In Person	Completed	Dr. Asiya Khadija	F	F	F
5012	1090	1027	Headache	24/05/2025	2164	Card	Online	Completed	Dr. Saifulal Abdullah	M	M	M
5013	896	1024	Diabetes	19/01/2025	1205	Digital Wallet	Online	Completed	Dr. Asif Zubair	M	M	M
5014	996	1027	Back Pain	07/01/2025	890	Insurance	In Person	Completed	Dr. Saba Kashif	M	F	F
5015	1463	1003	Hypertension	04/04/2025	1842	Cash	Online	Completed	Dr. Kamran Ahmed	M	M	M
5016	1528	1001	Hypertension	16/03/2025	2179	Insurance	In Person	Completed	Dr. Muhamr Shehla	F	M	M
5017	1190	1027	Headache	28/02/2025	1774	Digital Wallet	In Person	Completed	Dr. Sonia Hamza	M	F	F
5018	366	1004	Hypertension	29/01/2025	822	Card	Online	Completed	Dr. Sara Rizwan	M	F	F
5019	1449	1009	Migraine	02/12/2024	1122	Cash	Call	Completed	Dr. Waqas Hafsa	F	M	M
5020	1453	1027	General Checkup	12/08/2024	2043	Insurance	In Person	Completed	Dr. Shahbaz Hamza	M	M	M
5021	127	1001	Hypertension	25/07/2024	1435	Card	Call	Completed	Dr. Abida Khadija	F	F	F
5022	1538	1027	Headache	01/09/2024	1740	Card	Online	Completed	Dr. Shazia Sara	F	F	F
5023	551	1027	Headache	27/09/2024	2265	Cash	In Person	No-Show	Dr. Muhamr Zehra	F	M	M
5024	1429	1004	Hypertension	30/04/2025	1201	Cash	Call	Cancelled	Dr. Abdul Lubna	F	M	M
5025	770	1027	General Checkup	15/05/2025	902	Cash	Online	No-Show	Dr. Tasin Madina	F	F	F


Ce jeu de données est simple à comprendre, bien structuré et parfait pour apprendre à faire une modélisation en étoile et un cube OLAP.

II. Création d'un ETL sous Talend et cube OLAP :

L'objectif est de construire un Data Warehouse à partir d'un fichier de données hospitalières téléchargé depuis Kaggle.


a) Création du job sur le logiciel Talend :

Dans l'onglet repository, j'ai fait un clic droit sur Jobs et choisi Créer un Job.



b) Création de la métadonnée :

- a) Dans l'onglet repository, on clique dans métadonnées puis j'ai fait un clic droit sur fichier délimité puis sur créer un fichier délimité.



- b) Ensuite faut donner un nom a la métadonnée, sélectionner le fichier CSV, choisir le format (Windows), et spécifier le séparateur (comma) et enfin en clique sur finish

Nouveau fichier délimité

Fichier - Étape 1 de 4

⚠ Il est déconseillé de laisser vide le champ Objectif.

Nom:

Objectif:

Description:

Créé par: user@talend.com

Verrouillé par:

Version: 0.1

Statut:

Chemin d'accès:

< Back Next > Finish Cancel

Nouveau fichier délimité

Fichier - Étape 2 de 4

Ajouter un fichier de métadonnées au référentiel
Définissez le chemin d'accès au fichier et les paramètres de format

Paramètres du fichier

Serveur: Localhost 127.0.0.1

Fichier: C:/Users/ASUS/Downloads/hospital_data_10_colonnes_pour_Talend.csv

Format: WINDOWS

Visualiseur de fichier

```
Week Ending Date,Geographic aggregation,Number of Inpatient Beds,Number of Pediatric Inpatient beds,Number of Inpatient Beds Occupied,Number of Pediatric Inpatient Beds Occupied
2023-08-12,WA,10650.0,482.0,9040.0,339.0,1623.0,1309.0,226.0,17.0
2023-08-12,WI,10752.0,425.0,7574.0,286.0,1566.0,1014.0,86.0,2.0
2023-08-12,WV,4813.0,256.0,3701.0,139.0,639.0,468.0,47.0,1.0
2023-08-12,WY,1318.0,25.0,559.0,6.0,114.0,40.0,4.0,1.0
2023-08-19,AK,1354.0,77.0,1054.0,43.0,184.0,139.0,12.0,0.0
2023-08-19,AL,12977.0,510.0,9760.0,286.0,1668.0,1296.0,248.0,8.0
2023-08-19,AR,7453.0,427.0,5201.0,295.0,1143.0,864.0,97.0,4.0
2023-08-19,AS,150.0,28.0,63.0,7.0,7.0,4.0,0.0,0.0
2023-08-19,AZ,13553.0,873.0,10426.0,596.0,2026.0,1326.0,136.0,8.0
2023-08-19,CA,60499.0,4180.0,46531.0,2619.0,9795.0,6548.0,1479.0,34.0
2023-08-19,CO,10249.0,687.0,6741.0,371.0,1642.0,989.0,85.0,0.0
2023-08-19,CT,7432.0,480.0,5724.0,344.0,1192.0,775.0,110.0,1.0
2023-08-19,DC,2798.0,274.0,2184.0,733.0,555.0,428.0,37.0,1.0
```

Fichier - Étape 3 de 4

Ajouter un fichier de métadonnées au référentiel
Définissez les paramètres du Job de passage

Paramètres du fichier

Encodage: US-ASCII

Séparateur de champs: Comma Caractère correspondant: "

Séparateur de lignes: Standard EO Caractère correspondant: "\n"

Paramètres du caractère d'échappement

CSV ☒ Délimité

Caractère d'échappement: Vider

Entourage du texte: Vider

☐ Scinder la ligne avant le champ

Lignes à ignorer

Si des lignes doivent être ignorées, spécifiez les paramètres suivants

En-tête: ☒ 1

Pied de page: ☐

☐ Ignorer les lignes vides

Limite de lignes

Si le nombre de lignes doit être limité, spécifiez ce nombre

Limite:

Aperçu Sortie

☒ Définir la ligne d'en-tête comme nom de colonnes Actualiser l'aperçu

Week Ending Date	Geographic aggregation	Number of Inpatient Beds	Number of Pediatric Inpatient beds	Number of Inpatient Beds Occupied	Number of Pediatric Inpatient Beds Occupied
2023-08-12	WA	10650.0	482.0	9040.0	339.0
2023-08-12	WI	10752.0	425.0	7574.0	286.0
2023-08-12	WV	4813.0	256.0	3701.0	139.0

Exporter en tant que contexte Revenir au contexte précédent

Nouveau fichier délimité

Fichier - Étape 4 de 4

Ajouter un schéma au référentiel
Définissez le schéma

Nom: metadata

Commentaire:

Schéma

Cliquez pour mettre à jour la prévisualisation du schéma.


Description du schéma

Colonne	Clé	Type	☒ N..	Modèle de date (Ctrl+D)	Longueur	Précision	Par défaut	Commentaires...
Week_Ending_Date	☒	Date	☒	"dd-MM-yyyy"	10	0		
Geographic_aggregation	☐	String	☒		2	0		
Number_of_Inpatient_Beds	☐	String	☒		7	0		
Number_of_Pediatric_Inpatient...	☐	String	☒		6	0		
Number_of_Inpatient_Beds_Oc...	☐	String	☒		7	0		
Number_of_Pediatric_Inpatient...	☐	String	☒		6	0		
Number_of_ICU_Beds	☐	String	☒		6	0		
Number_of_ICU_Beds_Occupied	☐	String	☒		6	0		


c) Conception des composants ETL :

a) tFileInputDelimited : Ce composant fait le rôle de l'extraction (l'étape E de l'ETL) des données. Il lit le fichier ligne par ligne.

- Le composant se trouve à gauche dans la palette de Talend, il suffit juste de le glisser depuis la palette et le déposer dans l'espace de travail.




- Pour afficher ses propriétés on clique sur le composant, les propriétés s'affiche dans le panneau composant





- Sur le champ nom du fichier on ajoute la métadonnée qu'on a créé auparavant


- b) **tMap** : c'est le composant le plus important, il manipule les données c'est l'étape de la transformation (T dans ETL). Son rôle est de prendre des colonnes en entrée (input) et produit des colonnes en sortie(output), permet de les renommer, les modifier ou d'appliquer des formules complexes.
- Depuis la palette on le glisse et le dépose dans l'espace de travail.




- Pour le relier avec tFileInputDelimited : on clique sur tFileInputDelimited puis ligne principale et la glisser vers tMap. Cela crée un flux entre le fichier d'entrée et tMap.
- La configuration de tMap : on double clique sur tMap pour ouvrir l'éditeur, les colonnes input apparaissent dans le panneau de gauche.



- Pour créer un data warehouse faut créer plusieurs outputs pour notre cas on a créé 6 tables de dimensions et une table de fait :
 - Dim_date : la dimension date, sont les données liées au temps.
 - Dim_rdv : contient l'id du rdv, le mode de prise de rdv et le statue du rdv
 - Dim_Docteur : contient l'id de docteur son nom ainsi que son gender
 - Dim_maladie : a le nom de la maladie et son id
 - Dim_patient : : contient l'id du patient son nom ainsi que son gender
 - Dim_mode_payment : contient l'id du payment et le mode de payment
 - Fact_hopital : contient toutes les valeurs qu'on veut analyser. C'est la table centrale du modèle en étoile elle contient la mesure numérique(payment_amount) et les dimensions (axes d'analyse)
- La création des outputs se fait en cliquons sur le bouton +en haut a droite dans l'éditeur tMap.



- Puis faire le mapping pour chaque sortie on glisse les inputs vers chaque output correspondant




- A la fin cliquer sur appliquer puis ok en bas à droite pour valider le tMap.




c) tFileOutputDelimited : son rôle est d'enregistrer les données traitées dans un nouveau fichier. C'est la porte de sortie dans le flux ETL (chargement, load).

- On trouve le composant dans la palette et on le fait déposer sur l'espace de travail



- Pour chaque output on place le composant tFileOutputDelimited puis on relie la sortie du tMap au tFileOutputDelimited correspondant.



- Configuration du composant : dans l'onglet Component on spécifie le nom du fichier de sortie de chaque composants (les 7 composants on leurs donne un nom de fichier de sortie nouveau et différent).

output_maladies(tFileOutputDelimited_1)

Paramètres simples	Type de propriété	Built-in
Paramètres avancés	☐ Utiliser le flux de sortie	
Paramètres dynamiques	Nom de fichier "C:/Users/DELL/Downloads/out_maladie.csv"	
Vue	Séparateur de lignes "\n"	Séparateur de champs ","
Documentation	☐ Écrire à la suite de ☒ Inclure l'en-tête ☐ Compresser en tant que fichier zip	
	Schéma	Built-in Modifier le schéma Sync colonnes

output_rdv(tFileOutputDelimited_2)

Paramètres simples	Type de propriété	Built-in
Paramètres avancés	☐ Utiliser le flux de sortie	
Paramètres dynamiques	Nom de fichier "C:/Users/DELL/Downloads/out_rdv.csv"	
Vue	Séparateur de lignes "\n"	Séparateur de champs ","
Documentation	☐ Écrire à la suite de ☒ Inclure l'en-tête ☐ Compresser en tant que fichier zip	
	Schéma	Built-in Modifier le schéma Sync colonnes

output_facthopital(tFileOutputDelimited_3)

Paramètres simples	Type de propriété	Built-in
Paramètres avancés	☐ Utiliser le flux de sortie	
Paramètres dynamiques	Nom de fichier "C:/Users/DELL/Downloads/out_fact.csv"	
Vue	Séparateur de lignes "\n"	Séparateur de champs ","
Documentation	☐ Écrire à la suite de ☒ Inclure l'en-tête ☐ Compresser en tant que fichier zip	
	Schéma	Built-in Modifier le schéma Sync colonnes

output_modepayment(tFileOutputDelimited_4)

Paramètres simples	Type de propriété	Built-in
Paramètres avancés	☐ Utiliser le flux de sortie	
Paramètres dynamiques	Nom de fichier "C:/Users/DELL/Downloads/out_modepayment.csv"	
Vue	Séparateur de lignes "\n"	Séparateur de champs ","
Documentation	☐ Écrire à la suite de ☒ Inclure l'en-tête ☐ Compresser en tant que fichier zip	
	Schéma	Built-in Modifier le schéma Sync colonnes

output_patient(tFileOutputDelimited_5)

Paramètres simples	Type de propriété	Built-in
Paramètres avancés	☐ Utiliser le flux de sortie	
Paramètres dynamiques	Nom de fichier "C:/Users/DELL/Downloads/out_patient.csv"	
Vue	Séparateur de lignes "\n"	Séparateur de champs ","
Documentation	☐ Écrire à la suite de ☒ Inclure l'en-tête ☐ Compresser en tant que fichier zip	
	Schéma	Built-in Modifier le schéma Sync colonnes

output_date(tFileOutputDelimited_6)

Paramètres simples	Type de propriété	Built-in
Paramètres avancés	☐ Utiliser le flux de sortie	
Paramètres dynamiques	Nom de fichier "C:/Users/DELL/Downloads/out_date.csv"	
Vue	Séparateur de lignes "\n"	Séparateur de champs ","
Documentation	☐ Écrire à la suite de ☒ Inclure l'en-tête ☐ Compresser en tant que fichier zip	
	Schéma	Built-in Modifier le schéma Sync colonnes

outputbdd_docteur(tDBOutput_7)(PostgreSQL)

Paramètres simples	Database	PostgreSQL	Appliquer
Paramètres avancés	Type de propriété	Référentiel	Bases de données (POSTGRES)
Paramètres dynamiques	☐ Utiliser une connexion existante		
Documentation	Version de la base de données V9 et plus		
	Hôte	"localhost"	Port "5433"
	Base de données	"Data_projet"	Schéma ""
	Utilisateur	"postgres"	Mot de passe "*****"
	Table	"Dim_doc"	
	Action sur la table Supprimer la table si elle existe et la créer		Action sur les données Update ou insert


d) Exécution

- Lorsque le Job s'exécute, Talend écrit les données issues du tMap dans le fichier CSV de sortie.

```
Démarrage du Job hopital123 à 13:49 08/12/2025.
[statistics] connecting to socket on port 3521
[statistics] connected
[statistics] disconnected

Job hopital123 terminé à 13:49 08/12/2025. [Code de sortie
```


- Les fichiers de sortie s'enregistrent.




d) Création de la base de données :

a) Création de la base de données dans pgAdmin 4 :


- On clique droit sur data base puis create data base.



- Une fenêtre apparaît, ou on doit nommer notre data base puis sauvegarder.




- Actualiser avec refresh pour que le nom de la data base apparaisse




b) Créer la connexion PostgreSQL dans Talend :

- Dans repository puis Metadata, un clic droit sur DB connections créer une connexion, une fenêtre apparaît.




- On nomme la connexion avec le même nom que celui du data base qu'on a créé dans pgAdmin, et remplir les paramètres.

- Puis tester la connexion.




- Et enfin sauvegarder la connexion dans le Repository (cette connexion c'est juste un test le vrai nom de ma connexion et de ma data base est projet data).



- c) tPostgresqlOutput : Ce composant permet de prendre un flux de données qui vient d'un tMap ou d'un tFileInputDelimited, et de l'insérer dans une table PostgreSQL (il peut créer une table dans Postgress, insérer des données et mettre à jour ou remplacer des données).

- Pour chaque output on lui place un composant et le relier avec.



- On double tape sur le composant tDBOutput, dans les composants on remplit les paramètres simples (on refait la même chose pour chaque composant, 6 au total) :

- Property Type : choisir Repository (pour utiliser la connexion créée).
- Database : choisir POSTGRESQL cela remplit automatiquement host, port, data base et user.
-
- Table : saisir le nom de la table à créer
- Action on table : Create table pour que Talend créera la table à la première exécution si elle n'existe pas.

- Action on data : Insert, pour insérer les lignes.

Database PostgreSQL Appliquer

Type de propriété Référentiel Bases de données (POSTGRES)

☐ Utiliser une connexion existante

Version de la base de données V9 et plus

Hôte localhost Port 5433

Base de données Data_projet Schéma

Utilisateur postgres Mot de passe

Table fact_hopital

Action sur la table Supprimer la table si elle existe et la créer Action sur les données Update ou insert

Schéma Built-in Modifier le schéma Sync colonnes

☐ Utiliser les options spatiales

Source de données

This option only applies when deploying and running in the Talend Runtime

☐ Spécifier un alias de source de données


☐ Arrêter en cas d'erreur

- e) Exécution du job : dans l'onglet exécuter le job, on clique sur exécuter pour lancer l'exécution.

```
Starting job ETL_hospital at 23:50 13/11/2025.
[statistics] connecting to socket on port 3417
[statistics] connected
[statistics] disconnected
Job ETL_hospital ended at 23:50 13/11/2025. [exit code = 0]
```

Talend va Lire le fichier source via tFileInputDelimited, transforme et répartit les données via tMap, et crée la table si besoin et insère les données.

- f) Vérification dans pgAdmin : Dans pgAdmin on actualise la base de données (refresh), puis aller dans schémas, public, tables là ou nos 6 tables créer s'affiche.



Voici nos tables :

Tables (7)
> Dim_Docteur
> Dim_mode_payment
> Dim_patient
> Dim_rdv
> dim_date
> dim_maladie
> fact_hopital

1
2

```
SELECT * FROM public."Dim_Docteur"
ORDER BY "doct_Id" ASC
```

Data OutputMessagesNotifications

Showing rows: 1 to 9Page No: 1 of 1

	doct_Id [PK] integer	Fname_Doc character varying	Genderdoc character varying
1	1001	Dr. Falak	F
2	1002	Dr. Wajeeha	F
3	1003	Dr. Muhammad	M
4	1004	Dr. Sakina	F

QueryQuery History

1
2

```
SELECT * FROM public."Dim_mode_payment"
ORDER BY id_payment ASC
```

Data OutputMessagesNotifications

Showing rows: 1 to 1000

	mode_of_payment character varying	id_payment [PK] integer
1	Insurance	1
2	Card	3
3	Digital Wallet	5
4	Insurance	7
5	Insurance	9
6	Card	11

Total rows: 1500Query complete 00:00:04.417

QueryQuery History

1
2

```
SELECT * FROM public."Dim_patient"
ORDER BY "patient_Id" ASC
```

Data OutputMessagesNotifications

Showing rows: 1 to 348

	patient_Id [PK] integer	F_Name_patient character varying (8)	Gender_patient character varying (1)
1	100	Iram	F
2	112	Rayyan	M
3	113	Faisal	M
4	122	Zoya	M
5	127	Khadija	F
6	139	Arfa	F

Successfully run. Total query runtime: 3 seconds

1
2

```
SELECT * FROM public."Dim_rdv"
ORDER BY "appoIntment_Id" ASC
```

Data OutputMessagesNotifications

Showing rows: 1 to 400Page No: 1

	appoIntment_Id [PK] integer	mode_of_appointment character varying (9)	appointment_status character varying
1	5000	Call	Completed
2	5001	In Person	Completed
3	5002	Call	Completed
4	5003	Call	Completed
5	5004	Online	Cancelled
6	5005	Call	Completed

Successfully run. Total query runtime: 3 seconds

PostgreSQL 18/Debian 12.1

Total rows: 400Query complete 00:00:03.077

1
2

```
SELECT * FROM public.dim_date
ORDER BY "ID_date" ASC
```

Data OutputMessagesNotifications

Showing rows: 1 to 400Page No: 1

	appointment_Date timestamp without time zone	ID_date [PK] integer
1	2024-11-27 00:00:00	1
2	2024-09-24 00:00:00	3
3	2024-09-07 00:00:00	5
4	2025-05-30 00:00:00	7
5	2024-09-25 00:00:00	9
6	2024-07-16 00:00:00	11

Successfully run. Total query runtime: 3 seconds

Total rows: 400Query complete 00:00:00.116

QueryQuery History

1
2

```
SELECT * FROM public.fact_hopital
ORDER BY "appoIntment_Id" ASC, "doct_Id" ASC, "patient_Id" ASC, "ID_date" ASC
```

Data OutputMessagesNotifications

Showing rows: 1 to 400Page No: 1


appointment_Id [PK] integer	doct_Id [PK] integer	patient_Id [PK] integer	id_payment [PK] integer	ID_date [PK] integer	ID_reason [PK] integer	payment_amount character varying
5000	1027	1057	2	2	2	2139
5001	1009	1568	4	4	4	1204
5002	1024	449	6	6	6	2474
5003	1008	279	8	8	8	1148
5004	1001	1089	10	10	10	2031
5005	1009	450	12	12	12	2246

Query		Query History	Scratch
1	SELECT * FROM public.dim_maladie		
2	ORDER BY "ID_reason" ASC		


Data Output		Messages	Notifications
Showing rows: 1 to 400 Page No: 1 of 1			
	reason character varying (15)	ID_reason [PK] integer	
1	Back Pain	1	
2	Migraine	3	
3	Diabetes	5	
4	Migraine	7	
5	Hypertension	9	

e) Création du cube OLAP :


- a) Configuration du projet dans Pentaho Schéma Workbench : dans Pentaho Schéma Workbench on crée un nouveau fichier de schéma Mondrian et définir le nom du schéma ainsi que la source de données (connexion JDBC vers la base)




- b) Pour créer un nouveau cube on clique sur schéma puis add cube




- c) On donne un nom au cube(cube_olap)
d) Puis on associe la table de faits le cœur du cube, elle enregistre les événements ou transactions analysées.




- e) Puis on ajoute les mesures, en cliquant sur add mesure
- f) Et on définit son nom(payment_amount) et sa colonne dans la table de faits et l'agrégateur SUM




- g) Pour créer les dimensions, on clique sur add dimension. Et on précise son nom, sa source et ses hiérarchies





h) Validation du schéma : on clique sur save puis enregistrer et valider



Output :

```
<Schema name="New Schema3">
  <Cube name="cube_olap" visible="true" cache="true" enabled="true">
    <Table name="Fact_hopital" schema="public" alias=""> </Table>
    <Dimension type="StandardDimension" visible="true" foreignKey="doct_Id" name="docteur" caption="chef">
      <Hierarchy name="docteur" visible="true" hasAll="true">
        <Table name="Dim_Docteur" schema="public" alias=""> </Table>
        <Level name="id doc" visible="true" table="Dim_Docteur" column="doct_Id" nameColumn="doct_Id" type="Integer" uniqueMembers="false" levelType="Regular"> </Level>
        <Level name="name doc" visible="true" table="Dim_Docteur" column="Fname_Doc" nameColumn="Fname_Doc" type="String" uniqueMembers="false" levelType="Regular"> </Level>
        <Level name="gender" visible="true" table="Dim_Docteur" column="Genderdoc" nameColumn="Genderdoc" type="String" uniqueMembers="false" levelType="Regular"> </Level>
      </Hierarchy>
    </Dimension>
    <Dimension type="StandardDimension" visible="true" foreignKey="ID_date" name="date">
      <Hierarchy name="date" visible="true" hasAll="true">
        <Table name="dim_date" schema="public" alias=""> </Table>
        <Level name="id date" visible="true" table="dim_date" column="ID_date" nameColumn="ID_date" internalType="int" uniqueMembers="false" levelType="Regular"> </Level>
        <Level name="appointment_Date" visible="true" table="dim_date" column="appointment_Date" nameColumn="appointment_Date" uniqueMembers="false" levelType="Regular"> </Level>
      </Hierarchy>
    </Dimension>
    <Dimension type="StandardDimension" visible="true" foreignKey="ID_reason" name="maladie">
      <Hierarchy name="New Hierarchy 0" visible="true" hasAll="true">
        <Table name="dim_maladie" schema="public" alias=""> </Table>
        <Level name="id maladie" visible="true" table="dim_maladie" column="ID_reason" nameColumn="ID_reason" type="Integer" uniqueMembers="false" levelType="Regular"> </Level>
        <Level name="reason" visible="true" table="dim_maladie" column="reason" nameColumn="reason" type="String" uniqueMembers="false" levelType="Regular"> </Level>
      </Hierarchy>
    </Dimension>
    <Dimension type="StandardDimension" visible="true" foreignKey="patient_Id" name="patient">
      <Hierarchy name="New Hierarchy 0" visible="true" hasAll="true">
        <Table name="Dim_patient" schema="public" alias=""> </Table>
        <Level name="id patient" visible="true" table="Dim_patient" column="patient_Id" nameColumn="patient_Id" type="Integer" uniqueMembers="false" levelType="Regular"> </Level>
        <Level name="name patient" visible="true" table="Dim_patient" column="F Name_patient" nameColumn="F Name_patient" type="String" uniqueMembers="false" levelType="Regular"> </Level>
      </Hierarchy>
    </Dimension>
  </Cube>
</Schema>
```

```
<Dimension type="StandardDimension" visible="true" foreignKey="ID_reason" name="maladie">
  <Hierarchy name="New Hierarchy 0" visible="true" hasAll="true">
    <Table name="dim_maladie" schema="public" alias=""> </Table>
    <Level name="id maladie" visible="true" table="dim_maladie" column="ID_reason" nameColumn="ID_reason" type="Integer" uniqueMembers="false" levelType="Regular"> </Level>
    <Level name="reason" visible="true" table="dim_maladie" column="reason" nameColumn="reason" type="String" uniqueMembers="false" levelType="Regular"> </Level>
  </Hierarchy>
</Dimension>
<Dimension type="StandardDimension" visible="true" foreignKey="patient_Id" name="patient">
  <Hierarchy name="New Hierarchy 0" visible="true" hasAll="true">
    <Table name="Dim_patient" schema="public" alias=""> </Table>
    <Level name="id patient" visible="true" table="Dim_patient" column="patient_Id" nameColumn="patient_Id" type="Integer" uniqueMembers="false" levelType="Regular"> </Level>
    <Level name="name patient" visible="true" table="Dim_patient" column="F Name_patient" nameColumn="F Name_patient" type="String" uniqueMembers="false" levelType="Regular"> </Level>
  </Hierarchy>
</Dimension>
<Dimension type="StandardDimension" visible="true" foreignKey="appoIntment_Id" name="rendez-vous">
  <Hierarchy name="rendez-vous" visible="true" hasAll="true">
    <Table name="Dim_rdv" schema="public" alias=""> </Table>
    <Level name="Id appoIntment" visible="true" table="Dim_rdv" column="appoIntment_Id" nameColumn="appoIntment_Id" type="Integer" uniqueMembers="false" levelType="Regular"> </Level>
    <Level name="appointment_status" visible="true" table="Dim_rdv" column="appointment_status" nameColumn="appointment_status" type="String" uniqueMembers="false" levelType="Regular"> </Level>
    <Level name="mode_of_appointment" visible="true" table="Dim_rdv" column="mode_of_appointment" uniqueMembers="false"> </Level>
  </Hierarchy>
</Dimension>
<Dimension type="StandardDimension" visible="true" foreignKey="id_payment" name="payment">
  <Hierarchy name="payment" visible="true" hasAll="true">
    <Table name="dim_payment" schema="public" alias=""> </Table>
    <Level name="id payment" visible="true" table="dim_payment" column="id_payment" nameColumn="id_payment" type="Integer" uniqueMembers="false" levelType="Regular"> </Level>
    <Level name="mode payment" visible="true" table="dim_payment" column="mode_of_payment" nameColumn="mode_of_payment" uniqueMembers="false" levelType="Regular"> </Level>
  </Hierarchy>
</Dimension>
<Measure name="New Measure 0" column="payment_amount" datatype="Numeric" aggregator="sum" visible="true"> </Measure>
</Cube>
</Schema>
```


Ce qui montre que y'a pas d'erreur et le cube OLAP s'est créer

f) Analyse et Visualisation des Résultats :

Cette section présente les analyses réalisées à l'aide de Pentaho Report Designer afin d'apporter aux décideurs une vision claire et pertinente des résultats en transformant les données en informations utiles. Les visualisations créées (courbes, histogrammes, camemberts) permettent de repérer rapidement les tendances, les indicateurs clés et les informations utiles pour décider.


○ Étapes de réalisation :

1. *Connexion à la base* : On ouvre Pentaho Report Designer, puis ajouter une source de données de type JDBC, l'URL et le nom de la base, l'utilisateur et le mot de passe. Puis on fait un test de connexion pour vérifier que tout fonctionne



2. *Création des requêtes* : On crée une nouvelle requête dans Pentaho et on écrit le code SQL de chaque requête qu'on veut réaliser.

- Requête 1 : Quels sont les maladies les plus fréquents parmi les patients ?



Categorie	Valeur
Diabetes	16
General Checkup	13
Chest Pain	12
Hypertension	10
Headache	9
Back Pain	9
Fever	5
Migraine	5
Asthma	2

- Requête 2 : Combien de rendez-vous y a-t-il pour chaque statut de rdv ?

Nombre de Rendez-Vous par Statut	
Query Name	
Nombre de Rendez-Vous par Statut	
Static Query Query Scripting	
Query	
1	SELECT "appointment_status",
2	COUNT(*) AS "Nombre_de_Rendez_Vous"
3	FROM public."Dim_rdv"
4	GROUP BY "appointment_status"
5	ORDER BY "Nombre_de_Rendez_Vous" DESC;
6	

appointment_status	Nombre_de_Rendez_Vous
Completed	304
No-Show	38
Scheduled	36
Cancelled	22

- Requête 3 : Quel est le nombre de patients ayant eu un rendez-vous par mois et année ?

Query Name	
ptients_par_Date	
Static Query Query Scripting	
Query	
1	SELECT
2	TO_CHAR(d."appointment_Date", 'YYYY-MM') AS month,
3	COUNT(*) AS nbr_patients
4	FROM public."Dim_patient" p
5	JOIN public.dim_date d
6	ON p."patient_Id" = d."ID_date"
7	GROUP BY month
8	ORDER BY month;


month	nbr_patients
2024-07	7
2024-08	9
2024-09	1
2024-10	8
2024-11	5
2024-12	12
2025-01	8
2025-02	4
2025-03	3
2025-04	6
2025-05	7
2025-06	11

3. *Insertion des graphiques* : On sélectionne le type de graphique qu'on veut travailler avec (dans notre projet c'est l'histogramme). Puis on l'associe à nos requêtes SQL. Ensuite on définit les champs à utiliser la catégorie et la valeur, et on ajuste les couleurs, les légendes et les axes.

The screenshot displays a software interface for configuring a chart. At the top, there is a toolbar with various chart icons. Below the toolbar, the 'Bar Chart (Image)' configuration panel is active. It contains two main sections: 'Primary DataSource' and 'Secondary DataSource'. The 'Primary DataSource' section includes a 'CategorySet Data Collector (Chart Data)' table with columns 'Name' and 'Value'. The 'Secondary DataSource' section is currently empty. The 'Primary DataSource' table is populated with the following data:


Name	Value
Required	no-data-message
no-data-message	CHART.USER_NO_DATA_AVAL...
Title	chart-title
chart-title	chart-title-field
chart-title-field	title-font
title-font	SansSerif-BOLD-14
Options	stacked
stacked	False
stacked-percent	False
horizontal	False
bar-borders	False
max-bar-width	series-color
series-color	[#ff6600, #fcd202, #b0de09, ...
General	3-D
3-D	False
gridlines	True
bg-color	
bg-image	
show-border	False
border-color	
anti-alias	True
plot-bg-color	plot-fg-alpha
plot-fg-alpha	1.0
plot-bg-alpha	1.0
show-plot-border	False
label-font	SansSerif-8
Shadow	

- Pour la requête 1 : Quels sont les maladies les plus fréquents parmi les patients ?




Diabetes	16
General Checkup	13
Chest Pain	12
Hypertension	10
Headache	9
Back Pain	9
Fever	5
Migraine	5
Asthma	2

- Pour la requête 2 : Combien de rendez-vous y a-t-il pour chaque statut ?



Completed	304
No-Show	38
Scheduled	36
Cancelled	22

- Pour la requête 3 : Quel est le nombre de patients ayant eu un rendez-vous par mois et année ?



III. Modélisation décisionnelle : est le processus de représentation simplifiée et structurée d'un système réel pour mieux le comprendre et l'analyser.

Contient une table de faits et des tables de dimensions. Aussi des modèles (étoile, flocons de neige, constellation) qui représentent la manière dont la table de faits est reliée aux dimensions.

- *La table de faits* : Représente le cœur du modèle décisionnel. Elle contient des données quantitatives(mesures) et des clés étrangères vers les dimensions.
- *Table de dimensions* : contient des informations descriptives (qualitatives) qui sert à analyser les faits.

1. Modélisation en étoile : est une méthode de conception de base de données utilisée dans les Data Warehouse et OLAP. Permet d'organiser les données de manière à faciliter l'analyse et la prise de décision.

- Au centre se trouve la table de faits.
- Et autour d'elle y a les tables de dimensions reliées à la table de faits par des clés étrangères.
 - La modélisation en étoile conçue dans ce projet a pour objectif de faciliter l'analyse des activités médicales, les rendez-vous, les paiements, les médecins et les patients. Elle se compose d'une table de faits centrale et de 6 tables de dimensions qui permettent d'analyser les données selon différents axes.

a) Table de faits : *fact_hospital* : Elle contient les clés étrangères vers les différentes dimensions ainsi qu'une mesure quantitative.

- id_rdv : identifiant du rendez-vous
- id_docteur : identifiant du médecin
- id_patient : identifiant du patient
- id_mode_payment : identifiant du mode de paiement utilisé
- id_date : identifiant de la date du rendez-vous
- id_maladie : identifiant de la maladie
- payment_amount : montant payé lors du rendez-vous (mesure)

b) Table de dimension : *dim_rdv* : permet d'analyser les données selon la nature du rendez-vous et son statut.

- id_rdv : identifiant du rendez-vous
- mode_rdv : type de rendez-vous (call, in person, en ligne)
- status_rdv : état du rendez-vous (completed, no-show, cancelled, scheduled)

c) Table de dimension : *dim_doctor* : Cette dimension contient les informations relatives aux médecins.

- id_doctor : identifiant du médecin
- nom_doc : nom du médecin
- Gender_doc : gender du médecin

d) Table de dimension : *dim_patient* : décrit les patients qui ont pris un rendez-vous

- id_patient : *identifiant du patient*
- nom_patient : *nom du patient*
- gender : *gender du patient*

e) Table de dimension : *dim_mode_payment* : Elle permet d'étudier les préférences de paiement et leur répartition.

- id_payment : identifiant du mode de paiement
- mode_payment : type de paiement (insurance, card, digital wallet, cash)

f) Table de dimension : *dim_date* : permet d'effectuer des analyses temporelles.

- id_date : identifiant de la date
- date : date complète (dd/MM /yyyy)

g) Table de dimension : *dim_maladie* : Cette dimension décrit les maladies

- id_maladie : identifiant de la maladie
- maladie : nom de la maladie (back pain, migraine, diabète, hypertension, heedache...)




Figure : modélisation en étoile

